

Forecasting probabilístico como capa de salida para RiskGate

Experimento preliminar con GJR–GARCH y DeepAR-style

RiskGate Research

20 de julio de 2026

Resumen

Se estudia si un pronóstico probabilístico diario puede mejorar una regla de salida para posiciones largas. Se comparan buy-and-hold, un filtro EWMA, GJR–GARCH(1,1) con innovaciones t y una red recurrente global tipo DeepAR. Los umbrales se seleccionan exclusivamente en 2022–2023 y se evalúan desde 2024 sobre diez activos líquidos, con costo de 5 puntos base por cambio de exposición. GJR–GARCH elevó el Sharpe de 1.16 a 1.31 y redujo el drawdown máximo de -27.5% a -18.5% , sacrificando retorno. Sin embargo, el intervalo bootstrap al 90 % de la diferencia de Sharpe incluye cero. DeepAR-style quedó mal calibrado y no mostró valor. La evidencia justifica continuar investigando una capa de control de volatilidad, pero no integrar todavía una recomendación automática de venta en RiskGate.

1. Pregunta de investigación

La pregunta no es si un modelo puede predecir el precio puntual, sino si su distribución predictiva mejora una decisión accionable: mantener o reducir una posición durante la siguiente sesión. Las hipótesis registradas son:

1. un filtro de volatilidad GJR–GARCH puede reducir drawdown y mejorar rendimiento ajustado por riesgo;
2. un modelo recurrente probabilístico puede aportar señal direccional adicional;
3. cualquier modelo complejo debe superar a EWMA, no sólo a buy-and-hold.

Esta es una prueba sobre retornos del subyacente. No valida aún el momento óptimo de cierre de una opción, porque no se dispone de series históricas completas de bid/ask, volatilidad implícita y griegas.

2. Teoría

2.1. GJR–GARCH– t

Sea $r_t = \mu + \epsilon_t$, con $\epsilon_t = \sigma_t z_t$ y z_t estandarizado con distribución t . El modelo asimétrico utilizado es

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \gamma \epsilon_{t-1}^2 \mathbf{1}\{\epsilon_{t-1} < 0\} + \beta \sigma_{t-1}^2. \quad (1)$$

El parámetro γ captura que choques negativos pueden elevar más la volatilidad. El modelo pronostica riesgo condicional, no dirección. Por ello la regla sale del mercado cuando $\hat{\sigma}_{t+1}$ rebasa un umbral seleccionado fuera del conjunto de prueba. Como documenta el estudio de PF-Learning que motivó este trabajo, GJR–GARCH puede funcionar en regímenes cercanos a volatilidad estocástica clásica y fallar ante saltos acoplados al estado; se trata, entonces, de un filtro y no de una autoridad de venta.

2.2. DeepAR-style

DeepAR modela una familia de series mediante una red autorregresiva global y emite los parámetros de una distribución condicional [3]. En esta primera implementación, un LSTM de dos capas recibe una ventana de 40 sesiones con retorno, retorno absoluto, volatilidades a 5 y 20 días, momentum y cambio de volumen. La cabeza gaussiana produce (μ_t, σ_t) y se minimiza

$$\mathcal{L}_t = \log \sigma_t + \frac{1}{2} \left(\frac{r_{t+1} - \mu_t}{\sigma_t} \right)^2. \quad (2)$$

La regla mantiene exposición cuando $P(r_{t+1} < 0)$ no supera el umbral validado. Se denomina *DeepAR-style*, no DeepAR canónico: esta versión usa emisión gaussiana, covariables limitadas y un solo entrenamiento global.

2.3. De forecast a decisión

Para cada activo, la rentabilidad de la capa de salida es

$$r_{t+1}^{\text{strat}} = a_t r_{t+1} - c |a_t - a_{t-1}|, \quad a_t \in \{0, 1\}, \quad (3)$$

donde a_t se conoce al cierre de t y $c = 5$ puntos base. Esta alineación evita utilizar el retorno futuro para decidir. Una recomendación posterior para opciones deberá comparar la utilidad de mantener contra cerrar, traduciendo la distribución del subyacente a P&L mediante el payoff y las griegas.

3. Diseño experimental

Se descargaron precios diarios ajustados desde el endpoint público de Yahoo Finance para SPY, QQQ, IWM, AAPL, MSFT, NVDA, AMZN, GOOGL, META y TSLA. La división cronológica quedó fijada así:

- entrenamiento: 2015–2021;
- validación y selección de umbrales: 2022–2023;
- prueba final: 1 de enero de 2024 hasta la última observación disponible al ejecutar el estudio.

El conjunto de prueba contiene 6,370 observaciones activo–día. Los umbrales candidatos se fijaron antes de examinar el test: probabilidades entre 0.50 y 0.75 para DeepAR-style y cuantiles 65–95 de volatilidad para EWMA/GARCH. Se eligió el mayor Sharpe en validación. Las métricas son retorno y volatilidad anualizados, Sharpe sin tasa libre de riesgo, drawdown máximo, riqueza final, exposición y rotación.

La incertidumbre se estima con 2,000 réplicas de bootstrap de bloques móviles de 20 sesiones. Este bootstrap respeta parcialmente la dependencia temporal, aunque no corrige selección entre múltiples especificaciones.

4. Resultados

GJR–GARCH produjo la mejor razón retorno/riesgo y mucha menos rotación que EWMA. No obstante, la mediana bootstrap de la mejora de Sharpe sobre buy-and-hold fue 0.07, con intervalo al 90 % de $[-0.43, 0.51]$. La diferencia media de retorno diario tuvo intervalo $[-6.65, 1.63]$ puntos base. En consecuencia, no se puede descartar que la mejora observada sea ruido. Además, el umbral global

Cuadro 1: Resultados fuera de muestra desde 2024.

Modelo	Ret. anual	Vol. anual	Sharpe	Max DD	Exposición	Cambios
Buy & hold	27.1 %	23.2 %	1.16	−27.5 %	100.0 %	0
EWMA	16.3 %	14.5 %	1.13	−16.8 %	77.0 %	163
GJR–GARCH– t	20.3 %	15.5 %	1.31	−18.5 %	77.0 %	36
DeepAR-style	1.2 %	1.9 %	0.64	−2.8 %	0.5 %	44




Figura 1: Riqueza acumulada neta del costo supuesto, inicializada en uno.

dejó a TSLA sin exposición y generó exposiciones muy diferentes entre activos; una siguiente versión debe normalizar el forecast por el régimen histórico de cada serie o usar percentiles específicos por activo.

DeepAR-style tuvo exactitud direccional de 46.2 %, Brier de 0.332 para el evento negativo y cobertura de 83.7 % para un intervalo nominal de 90 %. El umbral validado fue el mínimo permitido, 0.50, pero aun así el modelo sólo mantuvo 0.5 % de exposición. Esto es un fallo de calibración/distribución, no evidencia de que “estar casi siempre en efectivo” sea una buena política. El resultado coincide con la advertencia del informe de PF-Learning: un modelo profundo puede rendir bien en el cuerpo de ciertas distribuciones y fallar en colas o regímenes distintos.

5. Interpretación

El experimento ofrece evidencia *prometedora pero insuficiente* para GJR–GARCH como control de riesgo. Su aparente valor está en reducir exposición durante alta volatilidad, no en identificar el máximo de precio. No hay soporte para integrar la versión actual de DeepAR-style. Tampoco se demuestra que GARCH “sepa cuándo vender”: sólo que una regla de alta volatilidad habría cambiado favorablemente el perfil observado en este test.

La comparación contra EWMA es importante. EWMA obtuvo un drawdown ligeramente menor, pero un Sharpe inferior, menor retorno y más de cuatro veces la rotación de GARCH. Hay señal

de que la estructura asimétrica y persistente de GARCH puede aportar algo más que un estimador barato, aunque la incertidumbre sigue siendo grande.

6. Amenazas a la validez

- Sólo se estudian diez activos estadounidenses líquidos y un periodo alcista relativamente corto.
- Existe sesgo de supervivencia y selección ex post del universo.
- No se modelan impuestos, spread variable, slippage, rendimiento del efectivo ni ejecución intradía.
- Una señal binaria de un día no representa todavía una operación completa con tesis, stop y objetivo.
- No se usan primas históricas de opciones; theta, vega y convexidad pueden invertir la decisión del subyacente.
- DeepAR-style no fue sometido a búsqueda amplia de arquitectura ni recalibración walk-forward.
- El bootstrap no incorpora incertidumbre por elegir universo, features y familias de modelos.

7. Siguiente experimento recomendado

Antes de integrar código en RiskGate se propone:

1. ampliar a varios ciclos de mercado y un universo definido ex ante, incluyendo activos retirados;
2. usar umbrales de volatilidad normalizados por activo y estados *hold/reduce/exit*, no sólo binarios;
3. añadir LightGBM cuantílico como benchmark, dado su desempeño en el estudio PF-Learning;
4. recalibrar DeepAR con emisión Student-*t*, PIT y calibración isotónica en validación;
5. evaluar reglas condicionadas a entradas reales de RiskGate y al nivel de invalidación;
6. recopilar snapshots históricos de opciones para traducir cada trayectoria a P&L multileg;
7. exigir mejora estable por activo, régimen y bloque temporal, con costos adversos.

8. Conclusión

La herramienta experimental sí tiene valor como mecanismo para decidir si vale la pena continuar. En esta primera corrida, la respuesta es selectiva: GJR-GARCH merece una segunda ronda como overlay de reducción de riesgo; DeepAR-style debe permanecer como challenger de investigación. Ninguno debe activar ventas automáticas todavía. La arquitectura futura debería ejecutar estos modelos en el motor Python y entregar a RiskGate distribuciones, confianza y razones; la política de salida y la aprobación humana permanecerían separadas.

Referencias

- [1] T. Bollerslev, “Generalized Autoregressive Conditional Heteroskedasticity,” *Journal of Econometrics*, 31, 1986.
- [2] L. Glosten, R. Jagannathan y D. Runkle, “On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks,” *Journal of Finance*, 48, 1993.
- [3] D. Salinas, V. Flunkert, J. Gasthaus y T. Januschowski, “DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks,” *International Journal of Forecasting*, 36, 2020.
- [4] T. Gneiting y A. Raftery, “Strictly Proper Scoring Rules, Prediction, and Estimation,” *Journal of the American Statistical Association*, 102, 2007.